



TECNOLÓGICO
NACIONAL DE MÉXICO®



"POR MI PATRIA Y POR MI BIEN"

Instituto Tecnológico de Ciudad Madero

Carrera: Ingeniería en Sistemas Computacionales

Materia: PROG. PARA CIENC. DE DAT.

Hora: 1:00 PM – 2:00 PM

Docente: JORGE PERALTA ESCOBAR

Nombre del alumno: Osteguín Hernández Ricardo

Semestre: Enero - mayo 2026



TECNOLÓGICO
NACIONAL DE MÉXICO®



"POR MI PATRIA Y POR MI BIEN"

Contenido

Aprendizaje Supervisado	3
Aprendizaje No Supervisado	4
Características principales:	4
Clasificaciones principales:	4
Aprendizaje por Refuerzo	5
Elementos centrales:	5
Ejecucion en código	6
.....	6
Introducción al aprendizaje automático en R	7
Aspectos destacados de R:	7
Algoritmos de Aprendizaje Automático	8
EJEMPLOS EN CODIGO	9
Análisis Exploratorio de Datos (EDA)	10
Metas del EDA:	10
Tipos de análisis:	10
Análisis Univariado	11
Análisis bivariante	13
Análisis multivariante	14



TECNOLÓGICO
NACIONAL DE MÉXICO®



Aprendizaje Supervisado

El aprendizaje supervisado representa una categoría fundamental del Machine Learning en la cual los modelos se entrenan utilizando un conjunto de datos que ya posee etiquetas predefinidas. En otras palabras, se le proporciona a la computadora tanto la información de entrada como la salida deseada, con la finalidad de que el algoritmo aprenda a identificar patrones y sea capaz de predecir resultados precisos cuando se enfrente a datos inéditos.

Este enfoque requiere procesar la información de forma iterativa para ir optimizando su nivel de precisión. Existen dos grandes divisiones en esta área: la clasificación, que se encarga de asignar datos a categorías específicas, y la regresión, enfocada en la predicción de valores numéricos continuos.

Entre los métodos analíticos más populares destacan los árboles de decisión, la regresión lineal, el algoritmo K-Nearest Neighbors (KNN), Random Forest y las Máquinas de Vectores de Soporte (SVM). Estas herramientas tienen aplicaciones críticas en sectores como la detección de fraudes bancarios, los diagnósticos médicos, el análisis de mercados financieros y los motores de recomendación.

Su principal fortaleza radica en la alta exactitud que puede alcanzar cuando se cuenta con un volumen extenso de datos de entrenamiento. No obstante, presenta ciertas limitaciones, como el arduo trabajo requerido para etiquetar los datos previamente y el riesgo de "sobreajuste" (overfitting), un escenario donde el modelo memoriza la información de entrenamiento pero fracasa al intentar generalizar frente a casos nuevos.



TECNOLÓGICO
NACIONAL DE MÉXICO®



Aprendizaje No Supervisado

En contraste, el aprendizaje no supervisado opera sobre bases de datos que carecen de etiquetas o categorías explícitas. El propósito de estos modelos es explorar la información de forma autónoma para revelar agrupamientos, correlaciones y estructuras que no son evidentes a simple vista.

Dado que el algoritmo no cuenta con una "respuesta correcta" de referencia durante su entrenamiento, la máquina debe deducir por sí misma las métricas de similitud entre los elementos evaluados.

Características principales:

- Procesa información no clasificada de forma autónoma.
- Su objetivo es descubrir patrones latentes.
- Es ideal para procesar volúmenes masivos de datos.
- Minimiza la necesidad de supervisión humana.

Clasificaciones principales:

- **Agrupamiento (Clustering):** Consiste en segmentar los datos en subconjuntos basados en atributos compartidos.
- **Reglas de Asociación:** Localiza dependencias o co-ocurrencias frecuentes entre distintos elementos.

Los algoritmos más recurrentes en esta rama son K-Means, Clustering Jerárquico, DBSCAN y Apriori. Comúnmente se utilizan para la segmentación de clientes, el reconocimiento de formas, la detección de anomalías y los sistemas de recomendación. Su mayor ventaja es que ahorra el costo de etiquetar datos y puede descubrir hallazgos insospechados, aunque sus resultados pueden ser complejos de interpretar y demandan un alto poder de procesamiento computacional.



TECNOLÓGICO
NACIONAL DE MÉXICO®



Aprendizaje por Refuerzo

Esta rama del Machine Learning se fundamenta en un proceso continuo de prueba y error. Consiste en un "agente" autónomo que interactúa dentro de un entorno dinámico, buscando maximizar una recompensa a largo plazo. En lugar de aprender con datos etiquetados, el agente descubre las mejores decisiones a través de estímulos positivos (recompensas) y negativos (penalizaciones) derivados de sus propias acciones.

Elementos centrales:

- **Agente:** La entidad encargada de tomar las decisiones.
- **Entorno:** El sistema o escenario donde opera el agente.
- **Acciones:** El conjunto de movimientos posibles que puede ejecutar.
- **Recompensa:** La retroalimentación de éxito o fracaso obtenida.
- **Estado:** La configuración y situación del entorno en un momento específico.

A través de la experiencia iterativa, el algoritmo formula estrategias óptimas. Este aprendizaje puede ser impulsado por refuerzo positivo (premiando el éxito) o negativo (castigando el error). Los algoritmos líderes incluyen Q-Learning, SARSA, Métodos de Monte Carlo y Deep Q Networks (DQN).

Sus aplicaciones abarcan desde la conducción autónoma y el control de robots hasta agentes virtuales en videojuegos y automatización industrial. Aunque posee una increíble capacidad de adaptación a escenarios cambiantes, requiere tiempos de entrenamiento muy prolongados y recursos de hardware considerables.



TECNOLÓGICO
NACIONAL DE MÉXICO®



Ejecucion en código

Figure 1







Figure 1





TECNOLÓGICO
NACIONAL DE MÉXICO®



Introducción al aprendizaje automático en R

La aplicación de R en el ámbito del Machine Learning resalta por ser un lenguaje de programación diseñado específicamente para el análisis estadístico y la manipulación de datos. Este entorno permite a los especialistas construir modelos predictivos para extraer información útil de bases de datos complejas.

R ofrece un vasto ecosistema de paquetes que simplifican enormemente la codificación de algoritmos de clasificación, regresión y clustering.

Aspectos destacados de R:

- Lenguaje nativo para las matemáticas y la estadística.
- Extensa biblioteca de herramientas para Machine Learning.
- Capacidades excepcionales para la representación gráfica de datos.
- Gran adopción en la investigación científica.

El ecosistema soporta modelos supervisados, no supervisados y por refuerzo, destacando librerías fundamentales como caret, ggplot2, randomForest, nnet y e1071. El flujo de trabajo típico involucra la recolección, limpieza, división de los datos (entrenamiento/prueba), entrenamiento del modelo y su posterior evaluación.

Es una herramienta open source con una comunidad global de respaldo y excelentes gráficos. Sin embargo, su curva de aprendizaje exige conocimientos estadísticos y puede presentar problemas de rendimiento al manejar volúmenes de datos extremadamente grandes.



TECNOLÓGICO
NACIONAL DE MÉXICO®



"POR MI PATRIA Y POR MI BIEN"

Algoritmos de Aprendizaje Automático

Los algoritmos son el núcleo técnico del Machine Learning; son las reglas matemáticas que otorgan a las máquinas la capacidad de asimilar conocimiento y tomar decisiones sin haber sido programadas línea por línea para cada tarea concreta. Se estructuran principalmente en tres metodologías:

1. **Supervisados:** Entrenan con históricos que incluyen las respuestas correctas. Excelentes para tareas predictivas. Ejemplos: Regresión Logística y Lineal, Random Forest, KNN, SVM y Árboles de Decisión. Aplicados en reconocimiento de imágenes y filtrado de spam.
2. **No Supervisados:** Exploran datos sin categorizar para hallar la estructura oculta. Ejemplos: DBSCAN, K-Means, Algoritmo Apriori y Clustering Jerárquico. Frecuentes en análisis de mercado y detección de fraudes.
3. **Por Refuerzo:** Basados en la experiencia autónoma dentro de un entorno buscando maximizar recompensas. Ejemplos: DQN, Q-Learning y SARSA. Indispensables en robótica y automatización de sistemas.


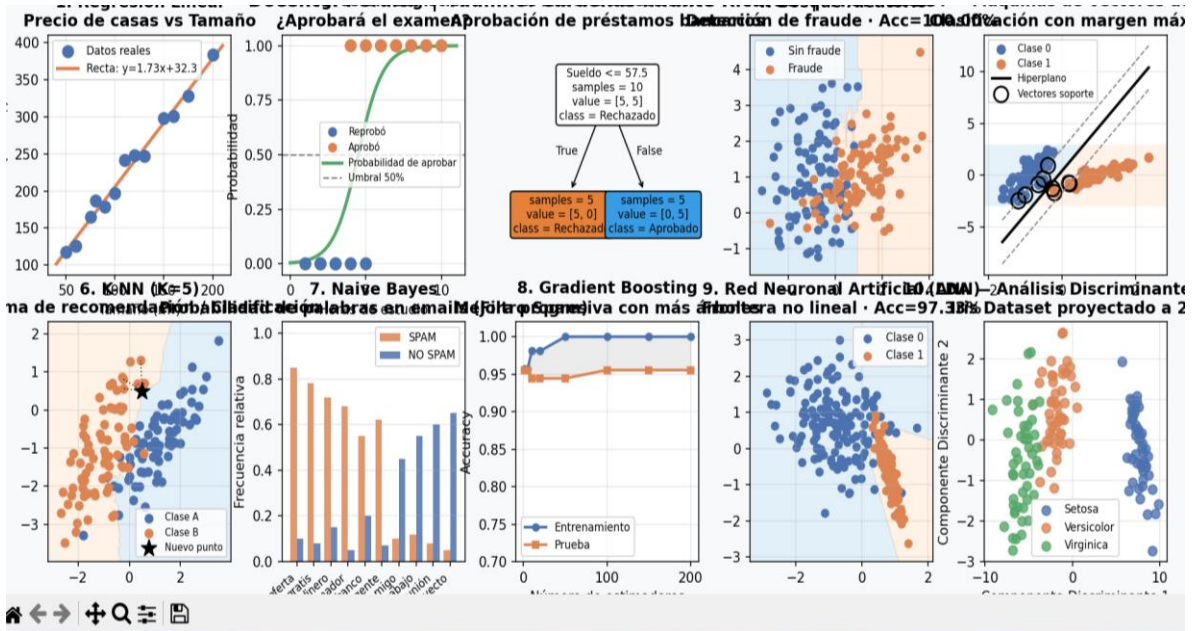
Estos métodos permiten procesar gigantescas cantidades de datos para mejorar la toma de decisiones. No obstante, exigen grandes recursos computacionales, amplios volúmenes de datos para ser precisos y requieren un monitoreo constante para evitar problemas como el sobreajuste.



TECNOLÓGICO
NACIONAL DE MÉXICO®



EJEMPLOS EN CODIGO





TECNOLÓGICO
NACIONAL DE MÉXICO®



Análisis Exploratorio de Datos (EDA)

El Análisis Exploratorio de Datos (EDA) constituye la fase preparatoria crucial en cualquier proyecto de ciencia de datos. Consiste en la aplicación de técnicas visuales y estadísticas para examinar, auditar y comprender un conjunto de datos antes de alimentar con ellos a un modelo de inteligencia artificial. Un buen EDA garantiza la integridad de los datos y, por consiguiente, la eficacia del modelo predictivo.

Metas del EDA:

- Identificar la arquitectura general de la información.
- Localizar valores nulos, registros duplicados o errores.
- Mapear tendencias y correlaciones.
- Detectar valores atípicos (outliers).
- Acondicionar la base para análisis avanzados.

Tipos de análisis:

1. **Univariado:** Examina una sola variable de manera aislada (mediante histogramas, medidas estadísticas o gráficos de barras) para conocer su distribución.
2. **Bivariado:** Cruza dos variables para identificar posibles dependencias o relaciones directas, comúnmente utilizando diagramas de dispersión o tablas de correlación.
3. **Multivariado:** Interrelaciona tres o más atributos simultáneamente, a menudo representado en mapas de calor o mediante el análisis de componentes principales.



TECNOLÓGICO
NACIONAL DE MÉXICO®




"POR MI PATRIA Y POR MI BIEN"

El proceso estándar incluye la recolección, el preprocesamiento, el análisis estadístico descriptivo y la generación de gráficos. Aunque representa una etapa que exige tiempo y perspicacia analítica, es vital para evitar sesgos, purificar los datos y maximizar el desempeño de los modelos de Machine Learning.

Ejercicio en código Python:

Análisis Univariado







TECNOLÓGICO
NACIONAL DE MÉXICO®




"POR MI PATRIA Y POR MI BIEN"

Figure 1



(x, y) = (14.49, 78)

Figure 1







TECNOLÓGICO
NACIONAL DE MÉXICO®



"POR MI PATRIA Y POR MI BIEN"

Análisis bivalente






TECNOLÓGICO
NACIONAL DE MÉXICO®



"POR MI PATRIA Y POR MI BIEN"

Figure 1



Análisis multivariante

Figure 1

